# Лабораторная работа 3 Транспонирование матрицы

Виноградов Дима Сергеевич · 11-400 · Вариант F: float, N = 4500

Система: Intel Core i5-12450H, 8 ядер / 12 логических процессоров, Windows; L1 суммарно 704 КиБ (данные 320, инструкции 384), L2 7 МиБ, L3 12 МиБ; GCC 15.2.0. Сборка C++17 с -O2 -fopenmp. Массивы выделены через malloc; все результаты проверены поэлементно, несовпадений 0. Один прогрев и пять замеров, в таблицах медианы; omp_get_wtime() измеряет только транспонирование; BW = $2N^2$sizeof(float)/t, ГБ = $10^9$ байт.

## 1 Порядок обхода при одном потоке

| N | rows, с | cols, с | BW rows, ГБ/с | BW cols, ГБ/с |
|---|---|---|---|---|
| 256 | < 0,001 | < 0,001 | н/д | н/д |
| 512 | 0,001 | < 0,001 | 2,10 | н/д |
| 1024 | 0,005 | 0,003 | 1,68 | 2,80 |
| 2048 | 0,054 | 0,048 | 0,62 | 0,70 |
| 4500 | 0,090 | 0,107 | 1,80 | 1,51 |

Нулевой отсчёт указан как < 0,001 с: наблюдаемый шаг таймера около 1 мс; для него BW не определена (н/д).

## 2 Размер блока при N = 4500 и одном потоке

| Блок b | 4 | 8 | 16 | 32 | 64 | 128 |
|---|---|---|---|---|---|---|
| Время, с | 0,028 | 0,023 | 0,022 | 0,020 | 0,021 | 0,027 |
| BW, ГБ/с | 5,79 | 7,04 | 7,36 | 8,10 | 7,71 | 6,00 |

## 3 Потоки при N = 4500 и b* = 32

Общая база ускорения: T(rows, 1 поток) = 0,090 с; 12 потоков добавлены к точкам ТЗ.

| Потоки | rows_omp, с | S rows_omp | blocked_omp, с | S blocked_omp |
|---|---|---|---|---|
| 1 | 0,089 | 1,01 | 0,027 | 3,33 |
| 2 | 0,047 | 1,91 | 0,020 | 4,50 |
| 4 | 0,024 | 3,75 | 0,013 | 6,92 |
| 8 | 0,020 | 4,50 | 0,010 | 9,00 |
| 12 | 0,022 | 4,09 | 0,011 | 8,18 |
| 16 | 0,019 | 4,74 | 0,012 | 7,50 |

## 4 False sharing при N = 4500 и 8 потоках

| Стратегия | Время, с | BW, ГБ/с |
|---|---|---|
| static | 0,019 | 8,53 |
| static, 1 | 0,023 | 7,04 |
| static, 8 | 0,026 | 6,23 |

Дополнительно: in-place без выходной матрицы — 0,037 с последовательно и 0,016 с на 8 потоках; blocked_omp на 8 потоках — 0,010 с. Восстановление исходных данных перед каждым in-place запуском исключено из замера.

## Вывод

При обходе rows подряд читается A, а при cols подряд записывается B: при N = 1024 cols быстрее (0,003 против 0,005 с), но при N = 4500 быстрее rows. Для N = 256 и части результатов N = 512 сравнение ограничено разрешением таймера. Лучший блок b* = 32: два блока float занимают 8 КиБ и помещаются в L1 данных ядра, тогда как для b = 128 требуется 128 КиБ; вместимость кеша является лишь одним из факторов оптимума. Блочная версия быстрее всего работает на 8 потоках, а переход к 12 и 16 увеличивает её время, поэтому заменять обязательные 16 потоков на 12 не требуется. Ускорение 9,00 относительно rows включает пользу блочного обхода: относительно blocked_omp на одном потоке выигрыш составляет 2,70 раза, близко к 2,65 для интеграла ЛР2 на 8 потоках. В отличие от интеграла, здесь почти нет арифметики, поэтому масштабирование ограничивают прежде всего обмен с памятью и когерентность кешей; более сильное ограничение нельзя доказывать одним сравнением этих ускорений. При static, 1 соседние элементы B обновляют разные потоки в общей кеш-линии, и время выросло с 0,019 до 0,023 с из-за false sharing и сопутствующих расходов. Стратегия static, 8 также не устранила проблему: восемь float занимают лишь 32 байта, а в измерениях время достигло 0,026 с. In-place экономит выходной массив, но в этих замерах уступает блочной параллельной версии.