Лабораторная работа №8. Гибридный BFS: MPI + OpenMP

Виноградов Дима Сергеевич · 11-400 · 05.11.2026

Ubuntu 24.04 / WSL2; i5-12450H, 12 логических процессоров; Open MPI 4.1.6, C++17, -O2 -fopenmp. Измеряемые конфигурации используют не более 8 рабочих потоков, привязка отключена.

Граф и алгоритм

Ориентированный граф хранится в CSR. Генератор Python Random(42): цепочка 0→1→…→N−1 плюс kN случайных дуг, петли и повторы сохраняются. Старт s=0. Base: N=100000, k=4. Small/large: N=10000/300000, k=4; dense: N=100000, k=16; hub: base плюс дуги 0→v для всех v>0. Все процессы читают один файл.

Последовательный BFS использует очередь. Гибридный распределяет индексы фронта rank, rank+P, …; OpenMP обрабатывает их через schedule(runtime). Каждый поток пишет в собственный vector. dist внутри параллельного участка только читается. После него списки объединяются в признаки, Allreduce(MAX) объединяет их между процессами, и последовательный проход по вершинам формирует одинаковый новый фронт. MPI вызывается только главным потоком (THREAD_FUNNELED).

Сборка: mpic++.openmpi -O2 -std=c++17 -DOMPI_SKIP_MPICXX -fopenmp bfs.cpp -o bfs
Запуск: OMP_NUM_THREADS=4 OMP_SCHEDULE=dynamic,1 mpiexec.openmpi
--use-hwthread-cpus --bind-to none -n 2 ./bfs graph.txt 0

Корректность и методика

Все расстояния совпали на всех рангах: максимум несовпадений 0; в пяти больших графах недостижимых вершин 0. Пройдены 16 проверок известного ответа для графа из 8 вершин с циклами, повторами и недостижимыми вершинами, стартами 0 и 6. Среднее трёх запусков; генерация, чтение, CSR и начальные буферы исключены. Tpar — максимум времени BFS по процессам, включая обмены; S=среднее Tseq / среднее Tpar, E=S/(P·T).

Base: процессы, потоки и одинаковое число рабочих потоков

P	T	P·T	Tseq, c	Tpar, c	S	E
1	2	2	0.002962	0.007206	0.411	0.206
2	2	4	0.003419	0.010197	0.335	0.084
4	2	8	0.003616	0.032529	0.111	0.014
2	1	2	0.004398	0.007944	0.554	0.277
2	4	8	0.003458	0.009776	0.354	0.044
1	8	8	0.002984	0.010976	0.272	0.034
8	1	8	0.007918	0.010769	0.735	0.092

При T=2 сравниваются P=1,2,4; при P=2 — T=1,2,4; при P·T=8 — 1×8, 2×4, 4×2, 8×1. Все строки используют dynamic,1 и один граф.

Размер, структура и планировка (P=2, T=4)

Граф: N / M	M/N	static, c	dynamic, c	S (dyn)	E (dyn)
small: 10000/49999	5.00	0.003363	0.005392	0.038	0.005
base: 100000/499999	5.00	0.015392	0.009776	0.354	0.044
large: 300000/1499999	5.00	0.020971	0.031869	0.727	0.091
dense: 100000/1699999	17.00	0.010401	0.011395	0.969	0.121
hub: 100000/599998	6.00	0.010880	0.007938	0.152	0.019

Фронты, нагрузка и коммуникации

Base: размеры фронтов 1, 2, 11, 44, 231, 1182, 5720, 23128, 48945, 19849, 868, 19. 12 уровней, максимум 48945; обработано по рангам [50003, 49997]. Hub: фронты [1, 99999], обработано [50001, 49999]. Число уровней включает начальный фронт.

Base: накопленное время Allreduce, максимум по рангам и среднее запусков, 0.003963 с из 0.009776 с BFS. Оно включает ожидание других процессов. На каждом уровне объединяется N целых чисел: 4N байт входа на процесс, для base — 4,8 МБ за 12 уровней (не фактический сетевой трафик).

Вывод: узкие фронты оставляют процессы без работы; равное число вершин не означает равного числа рёбер. В hub начальная вершина с большим числом соседей достаётся одному потоку, и dynamic не может разделить её список. Dynamic помогает при разной стоимости вершин, но добавляет расходы. При равном P·T меняются объём MPI-обменов и дублирование данных. CSR занимает около 4(N+1+M) байт на процесс, дополнительно нужны dist, признаки и списки. Плотный обмен избыточен при малом числе кандидатов; передача списков через Allgatherv могла бы уменьшить объём, но требует удаления повторов. Это расширение не реализовано. В измерениях гибридная схема не гарантирует ускорения.